Univerzitet u Novom Sadu

Tehnički fakultet „Mihajlo Pupin“

Zrenjanin

Korišćenje YOLO algoritma za prepoznavanje slika automobila u kišnim uslovima

Utilizing the YOLO Algorithm for car image recognition under rainy weather conditions

- Diplomski (master) rad -

Student: Nikola Kekez

Broj indeksa: MIT 38/24

Smer: Informacione tehnologije – softversko inženjerstvo

Zrenjanin, 2025

Univerzitet u Novom Sadu

Tehnički fakultet „Mihajlo Pupin“

Zrenjanin

Korišćenje YOLO algoritma za prepoznavanje slika automobila u kišnim uslovima

Utilizing the YOLO Algorithm for car image recognition under rainy weather conditions

- Diplomski (master) rad -

Mentor:

Doc. dr Višnja Ognjenović

Student: Nikola Kekez

Broj indeksa: MIT 38/24

Smer: Informacione tehnologije – softversko inženjerstvo

Zrenjanin, 2025

Sadržaj

Sadržaj....0
1. Uvod....1
2. Korišćene tehnologije....2
2.1. Google Colab....2
2.2. YOLOv8 (Ultralytics)....2
3. Teorijsko istraživanje mogućnosti YOLO arhitekture....3
3.1. Osnovni principi YOLO arhitekture....3
3.2. Evolucija YOLO modela....4
3.3. Primena YOLO algoritma u multimediji i saobraćaju....4
3.4. Pregled relevantnih istraživanja....5
4. Metodološki okvir istraživanja....10
4.1. Predmet istraživanja....10
4.2. Problem istraživanja....10
4.3. Cilj istraživanja....10
4.4. Hipoteze....10
4.5. Vrsta istraživanja....10
4.6. Način istraživanja....11
5. Eksperimentalno istraživanje....11
5.1. Organizacija dataset-a u Google Drive....11
5.2. Anotacija slika....11
5.3. Google Colab kod....12
6. Pregled rezultata....16
6.1. Razmatranje Google Drive foldera i rezultata različitih grupa slika....16
6.2. Rezultati slika grupe A....19
6.3. Rezultati slika grupe B....22
6.4. Rezultati slika grupe C....26
6.5. Rezultati slika grupe D....32
6.6. Prikaz rezultata na grafikonima....34
6.7. Zaključak rezultata....36
7. Zaključak....37
8. Literatura....38

1. Uvod

Razvojem algoritama za prepoznavanje oblika omogućeno je da se rade specifična istraživanja prepoznavanja. Algoritmi za semantičku segmentaciju, u određenoj meri mogu ili ne mogu da daju dobra prepoznavanja.

U savremenim uslovima saobraćaja, vremenski uslovi, poput kiše, magle i snega, značajno utiču na vidljivost i pouzdanost sistema za prepoznavanje objekata. Poseban izazov predstavlja detekcija automobila pri kišnim uslovima, gde kapljice kiše, refleksija svetlosti i smanjeni kontrast utiču na tačnost i pouzdanost detekcije. Stoga je analiza performansi YOLO algoritma [1] u uslovima različitog intenziteta kiše od posebnog značaja za unapređenje sistema autonomne vožnje i video-nadzora.

Predmet ovog master rada jeste ispitivanje efikasnosti YOLO algoritma u prepoznavanju automobila na slikama snimljenim pri različitim kišnim uslovima. Fokus istraživanja biće na analizi preciznosti detekcije u zavisnosti od intenziteta kiše, udaljenosti objekta i boje automobila. U eksperimentalnom delu biće izvršeno poređenje rezultata na datasetovima koji sadrže slike automobila bez kiše, sa slabom kišom, jakom kišom i automobilima čija boja ima sličnu nijansu kao kišno okruženje.

Cilj ovog rada jeste da se pruži detaljna analiza sposobnosti YOLO algoritma da prepozna automobile pri otežanim vizuelnim uslovima i da se utvrde faktori koji najviše utiču na preciznost detekcije.

2. Korišćene tehnologije

Od tehnologija korišćeno je Google Colaboratory (Colab) [2] okruženje, YOLOv8 model [1] razvijen od strane kompanije Ultralytics, eksperimenti su realizovani u programskom jeziku Python [3], dok je Google Drive [4] korišćen kao primarno skladište podataka.

2.1. Google Colab

Za eksperimentalni deo rada korišćeno je Google Colaboratory (Colab) okruženje, koje predstavlja cloud platformu zasnovanu na Jupyter Notebook sistemu. Colab omogućava pokretanje Python koda u okruženju koje podržava korišćenje CPU, GPU i TPU resursa, čime se značajno ubrzava proces obrade slika i obuke modela.



Slika 1. – Izgled Google Colab okruženja

2.2. YOLOv8 (Ultralytics)

Za detekciju automobila korišćen je YOLOv8 model razvijen od strane kompanije Ultralytics. YOLOv8 predstavlja naprednu verziju algoritma You Only Look Once i karakteriše ga:

- rad u realnom vremenu sa visokom brzinom inferencije
- unapređeni backbone i head arhitektura u odnosu na prethodne verzije
- optimizacija za različite uređaje (GPU, CPU, edge uređaji)
- integrisana podrška za obuku (training), evaluaciju i predikciju (inference)
- fleksibilan rad sa različitim formatima dataset-ova (YOLO, COCO, VOC) [5]

Model je korišćen u unapred istreniranoj verziji (yolov8s.pt), što omogućava da se odmah primeni na specifične skupove slika, bez potrebe za obukom od nule.

2.3. Programski jezik Python

Eksperimenti su realizovani u programskom jeziku Python, zbog njegove široke upotrebe u oblastima veštačke inteligencije i računarskog viđenja. Python pruža podršku kroz širok izbor biblioteka, kao što su:

- NumPy – za rad sa numeričkim nizovima i matricama [6]
- Pandas – za skladištenje i analizu rezultata u tabelarnom obliku [3]
- Matplotlib i Seaborn – za vizualizaciju rezultata (grafici i dijagrami) [7]
- OpenCV – za rad sa slikama (učitavanje, augmentacija, vizuelna provera detekcija) [4]

Kolorni prostori: OpenCV koristi BGR raspored kanala pri čitanju, dok su mnoge biblioteke i modeli (uključujući PyTorch/YOLO) konceptualno usklađeni sa RGB. Korektna konverzija sprečava pogrešne vizuelizacije.

Dimenzije i skaliranje: YOLOv8 internim „letterbox“ mehanizmom prilagođava rezoluciju (npr. 640×640). Važno je čuvati originalne slike i raditi crtanje okvira u nativnoj rezoluciji radi verne prezentacije rezultata.

2.4. Google Drive

Google Drive je korišćen kao primarno skladište podataka. [4] Svi skupovi slika (grupe A, B, C i D) organizovani su u odgovarajuće foldere, a rezultati eksperimenta (CSV fajlovi, JSON fajlovi i generisane slike sa bounding box-ovima) automatski se čuvaju u podfolderima na Drive-u. Ovakva integracija obezbeđuje trajno čuvanje rezultata i jednostavnu organizaciju dataset-a.

3. Teorijsko istraživanje mogućnosti YOLO arhitekture

3.1. Osnovni principi YOLO arhitekture

YOLO algoritam deli ulaznu sliku na mrežu (grid), gde svaka ćelija mreže predviđa da li se u njoj nalazi objekat. Za svaku ćeliju generišu se predikcije koordinata objekta, vrednosti verovatnoće (confidence score) i klasne pripadnosti. Ovakav pristup omogućava YOLO modelu da detektuje objekte izuzetno brzo, čak i na uređajima sa ograničenim hardverom.

Za razliku od drugih metoda, YOLO posmatra globalni kontekst slike i zbog toga ima manju sklonost ka detekciji lažnih pozitivnih rezultata u odnosu na metode koje analiziraju manje delove slike pojedinačno. Upravo zbog ove efikasnosti i brzine, YOLO je postao dominantan u primenama kao što su autonomna vožnja, pametni video-nadzor i analiza saobraćaja.

3.2. Evolucija YOLO modela

YOLOv1 (2016) [1] postavio je temelje za detekciju u realnom vremenu, ali je imao ograničenja u preciznosti, posebno kod manjih objekata. YOLOv2 i YOLOv3 (2017–2018) [9] doneli su značajna poboljšanja u preciznosti, podršku za više rezolucija i bolji balans između brzine i tačnosti.

YOLOv4 i YOLOv5 [4] omogućili su primenu naprednih tehnika optimizacije, kao što su data augmentation, batch normalization i bolje upravljanje anchor box parametrima. YOLOv8, [1] koji predstavlja jednu od najnovijih implementacija, donosi još bolju preciznost, manju latenciju i optimizaciju za različite platforme — od GPU servera do mobilnih uređaja.

3.3. Primena YOLO algoritma u multimediji i saobraćaju

YOLO (You Only Look Once) modeli se danas koriste u širokom spektru aplikacija koje zahtevaju analizu slika i video zapisa u realnom vremenu. U domenu saobraćaja, YOLO omogućava detekciju vozila, pešaka, saobraćajnih znakova i prepreka, što ga čini ključnom tehnologijom za razvoj autonomnih vozila i inteligentnih sistema za nadzor saobraćaja.

Pored toga, koristi se u bezbednosnim sistemima za prepoznavanje lica, praćenje objekata, analizu gužvi i automatizaciju industrijskih procesa. YOLO predstavlja jednu od najpopularnijih i najefikasnijih arhitektura za detekciju objekata u realnom vremenu. Za razliku od tradicionalnih pristupa koji problem detekcije posmatraju kao kombinaciju klasifikacije i pretrage regiona, on tretira detekciju kao zadatak jedinstvene regresije — ulazna slika se obrađuje samo jednom, a mreža simultano predviđa pozicije objekata i njihove klase.

YOLO arhitektura deli sliku na S×S mrežu (grid), pri čemu svaka ćelija pokušava da predvidi bounding box-ove i pripadajuće confidence score-ove. Model se uči tako da maksimizuje tačnost lokacije i klasifikacije objekata istovremeno — što omogućava izuzetno visoke brzine (često preko 60 FPS), pa se koristi u autonomnim vozilima, dronovima, bezbednosnim sistemima i industrijskoj automatizaciji.

Ključne prednosti YOLO pristupa:

- Ekstremna brzina – pogodan za real-time primene
- Detekcija više objekata odjednom u jednoj forward propagaciji
- Manje lažnih pozitivnih detekcija zahvaljujući globalnom sagledavanju slike
- Skalabilnost – dostupne verzije YOLOv3, YOLOv5, YOLOv8 i YOLO-NAS optimizovane za različite uređaje (edge, mobilne, GPU, cloud)

U produkcionim sistemima YOLO je naročito popularan jer omogućava balans između tačnosti i performansi, što ga čini praktičnim za primenu u realnim uslovima – od saobraćaja i medicine do maloprodaje i robotike.

Dodatni izazov u realnom okruženju predstavljaju nepovoljni vremenski uslovi, kao što su kiša, magla ili noćno okruženje sa smanjenom vidljivošću. Mokra kolovozna površina stvara refleksije farova automobila, dok kapljice kiše na kameri degradiraju vizuelni kvalitet slike. Tradicionalni algoritmi zasnovani na ručno definisanim karakteristikama imali bi značajan pad preciznosti u takvim uslovima. YOLO, međutim, zahvaljujući dubokim konvolucionim mrežama i „end-to-end“ učenju, poseduje sposobnost da nauči robusne reprezentacije objekata čak i u uslovima jakog vizuelnog šuma.

U poslednjim verzijama (YOLOv5, YOLOv8 i YOLO-NAS), integrisane su optimizacije poput automatske augmentacije podataka (npr. simulacija kiše, zamagljenja, low-light uslova), čime se značajno povećava otpornost algoritma na realne izazove.

3.4. Pregled relevantnih istraživanja

U literaturi posvećenoj detekciji objekata u otežanim vremenskim uslovima ističe se rad Kim, Jeon, Lim (2023) [10] koji sistematski ispituje ponašanje YOLO serije u ekstremno jakoj kiši. Autori uvode CALRA (CARLA-based) sintetički evaluacioni skup [8] kako bi kvantitativno izmerili degradaciju performansi od „normalnih“ do „ekstremnih“ padavina. Ideja je da se izbegnu ograničenja realnih skupova (ograničen broj scena i nepouzdane anotacije u kiši) i da se obezbedi kontrolisano menjanje intenziteta padavina uz tačan „ground truth“.

Na nivou metodologije, rad upoređuje više YOLO generacija (od v3 do v8) i meri mAP/preciznost/odziv, pokazujući da sve varijante trpe jasnu degradaciju u ekstremnoj kiši, iako novije verzije (v7–v8) pokazuju relativno veću robusnost. Ključni uzroci grešaka su kapljice na sočivu, odsjaji i zamućenja koji indukuju lažno pozitivne detekcije, naročito za male i udaljene objekte.

Ovim radom je skrenuta pažnja da standardni skupovi (COCO, KITTI) ne obuhvataju dovoljno kišnih scenarija i da je neophodna dopuna/finetuning modela na specifičnim vremenskim uslovima.

Pregled reference-stranice istog rada u ADS (SAO/NASA) repozitorijumu potvrđuje da je fokus na „extremely heavy rain“ i da je rukopis pozicioniran kao evaluacioni okvir (dataset + metrika) za YOLO u takvim uslovima. Iako je ADS discipline-agnostičan (agregat), njegova stranica vodi na iste osnovne izvore (apstrakt, citate, reference), čime se potvrđuje bibliografska slika rada i njegova uloga kao benchmark okruženja za testiranje modela u padavinama.

Širi kontekst dopunjuju radovi koji koriste CARLA kao simulacionu platformu za generisanje podataka i evaluaciju percepcije u lošim vremenskim uslovima. Na primer, CARLA simulator-based okviri za procenu pokazuju da porast intenziteta padavina utiče ne samo na detekciju objekata već i na lane detection, pri čemu su krive trake osetljivije na blokadu senzora kišom od pravih traka. Ovi nalazi indirektno upućuju na to da kiša menja i lokalne teksturalne tragove i globalnu kontrastnu strukturu scene — faktor koji je relevantan i za YOLO detekciju automobila.

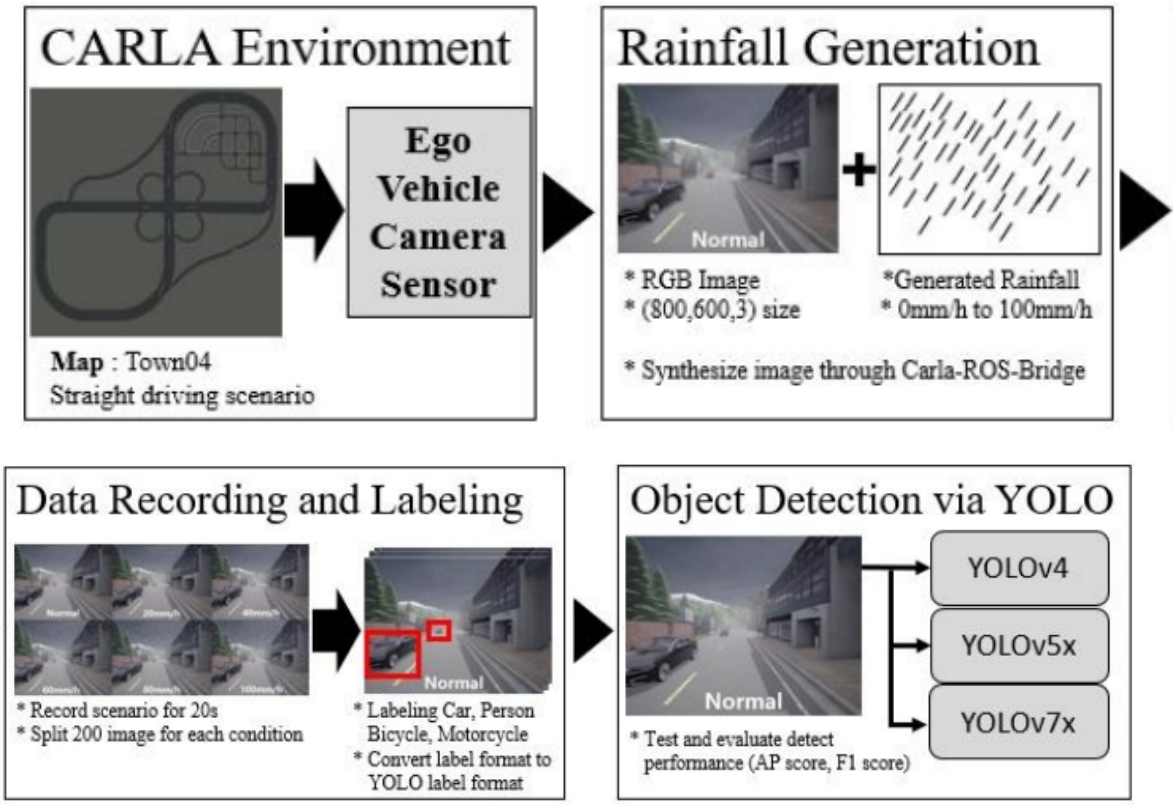
U preglednim radovima o multi-senzorskoj percepciji za autonomnu vožnju ističe se da su loši vremenski uslovi (kiša, sneg, magla) trajni izvor degradacije za kamere, ali i da fuzija senzora (kamera + LiDAR/radar) ublažava posledice time što kompenzuje nestabilnost vizuelnih tragova u kadrovima. Iako je predmet ovog master rada monomodalna (kamera + YOLO) detekcija, zaključci tih pregleda motivišu budući rad: kombinovanje YOLO sa pre-procesiranjem (deraining, dehazing) ili sa fuzijom senzora često vraća deo performansi izgubljenih usled padavina.

Nekoliko skorijih radova ide korak dalje i predlaže modifikacije detektora za loše vreme. Primer je D-YOLO (2024), koji uvodi degradation-aware komponente i strategije obrade kako bi se izbegla kaskada „deraining pa detekcija“, jer sam deraining može izgubiti latentne tragove korisne za detekciju; umesto toga, model nastoji da postane robustan na degradacije unutar jedinstvene mreže. Ovakvi pristupi dopunjuju poruku iz CALRA rada: umesto da se oslanjamo isključivo na pre-procesiranje, može se inkorporirati robustnost prema kiši direktno u detekcioni pipeline.

Vezano za generisanje i anotiranje podataka, literatura pokazuje da su sintetički skupovi nastali u CARLA okruženju korisni ne samo za evaluaciju već i za obuku (npr. alati tipa CarFree omogućavaju automatsko stvaranje 2D detekcionih skupova sa tačnim ground-truth koordinatama). Ovaj pravac je posebno značajan kada su realni kišni skupovi ograničeni ili teško anotabilni; pritom se insistira na variranju uslova (intenzitet padavina, doba dana, gužva, udaljenost objekta) kako bi se izbegla prekomerna specijalizacija modela.

Bibliografske baze i sekundarni izvori (DBLP zapisi, Google Scholar profili autora) navode i citiraju ovaj rad kao referentnu tačku za temu „YOLO u ekstremnoj kiši“, što potvrđuje njegov status u domenu. Ovi izvori ukazuju i na srodne radove istih autora koji razvijaju simulaciono-evaluacione okvire u CARLA (npr. za trake, blokade senzora) — dakle, postoji koherentan istraživački tok koji kombinuje simulaciju, anotacije i kvantitativnu evaluaciju pod različitim meteorološkim uslovima.

Relevantna istraživanja konvergiraju ka sledećim tezama: (i) degradacija performansi YOLO detekcije u kišnim uslovima je stabilno potvrđena; (ii) synthetic-to-real pristupi uz CARLA simulaciju omogućavaju kontrolisanu analizu intenziteta padavina i lak pristup tačnim anotacijama; (iii) novije YOLO verzije (v7–v8) jesu robusnije, ali i dalje pate od lažno pozitivnih i niskog poverenja za male/udaljene objekte u kiši; (iv) fuzija senzora i/ili degradation-aware modifikacije detekcionih mreža predstavljaju najperspektivnije smerove za ublažavanje posledica padavina; (v) za primene u realnom saobraćaju preporučuje se kombinovanje realnih i sintetičkih skupova, kao i evaluacija na vertikalno podeljenim scenarijima (slaba vs jaka kiša, dan/noć, boja vozila bliska boji scene).



Slika 2. – Workflow dijagram (slika preuzeta sa Kim et al., 2023)

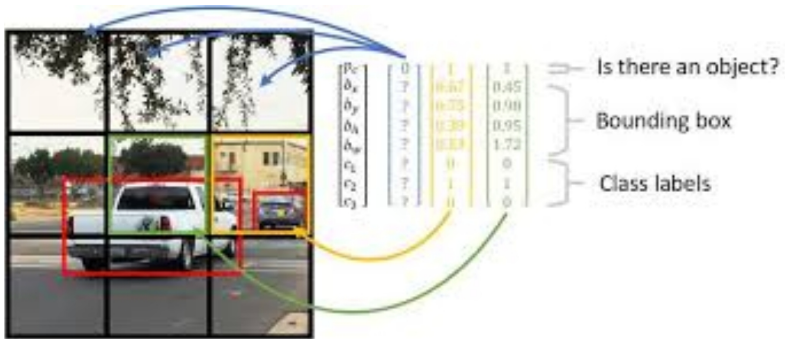
Na slici 2. se nalazi šema koja objašnjava kako su autori rada napravili eksperiment za evaluaciju YOLO modela u uslovima kiše koristeći CARLA simulator. [11]

Korišćen je CARLA simulator, mapa Town04, gde se vozilo kreće po unapred definisanoj putanji. Kamera na "ego vozilu" beleži scenu iz perspektive vozača.

Rainfall generation ubacuje generisane slike različitih inteziteta (od 0mm/h do 100mm/h), i na taj način se pravi dataset sa varijabilnim vremenskim uslovima – od potpuno suvih scena do ekstremno jakih padavina.

Data recording and Labeling – snimanje traje 20 sekundi za svaku simulaciju, dobija se po ~200 slika po uslovu. Slike se anotiraju (označavaju) sa bounding box-ovima za automobile, pešake, bicikle, motore, itd. Labeli se konvertuju u YOLO format, što omogućava jednostavno treniranje i testiranje.

Object Detection via YOLO – Dataset koristi evaluaciju različitih YOLO modela, performanse se mere standardnim metrikama (AP score i F1 score)



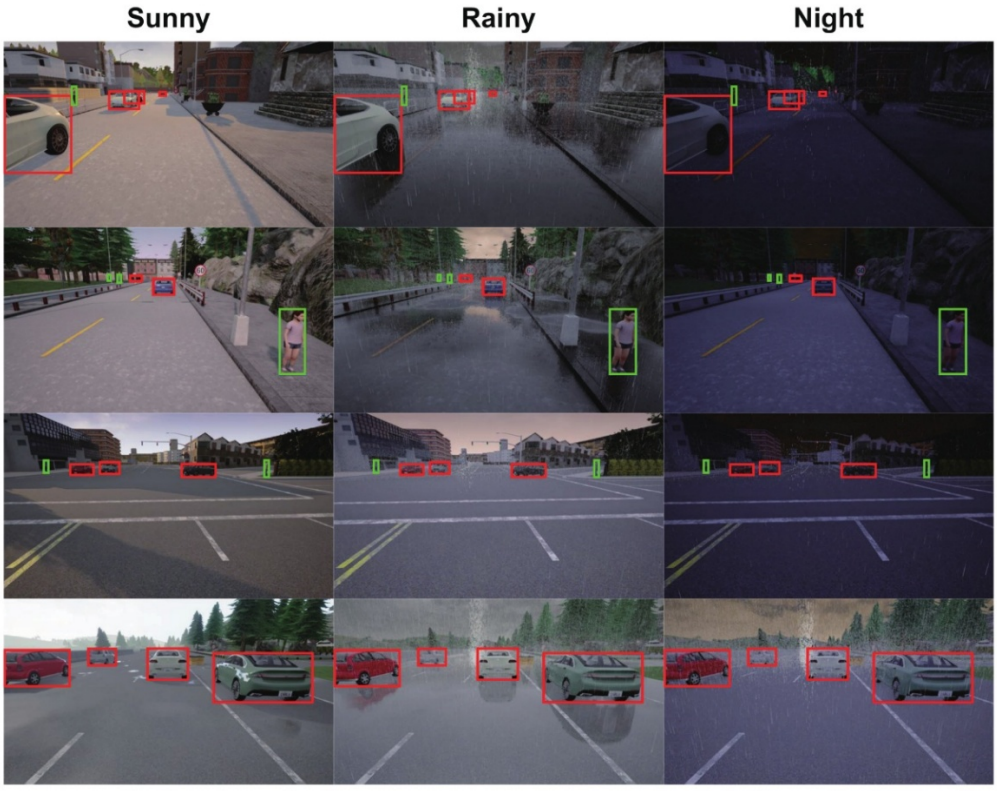
Slika 3. – Osnovni princip rada YOLO algoritma za detekciju objekata (slika preuzeta sa „Classification and Counting of Vehicle using Image Processing Techniques“, IJRASET, 2020)

Na slici 3. je prikazana mreža (grid cells), gde se ulazna slika deli na mrežu (npr. 3x3 u ovom primeru). Svaka ćelija mreže je zadužena da "predviđa" da li u njoj postoji objekat. [12]

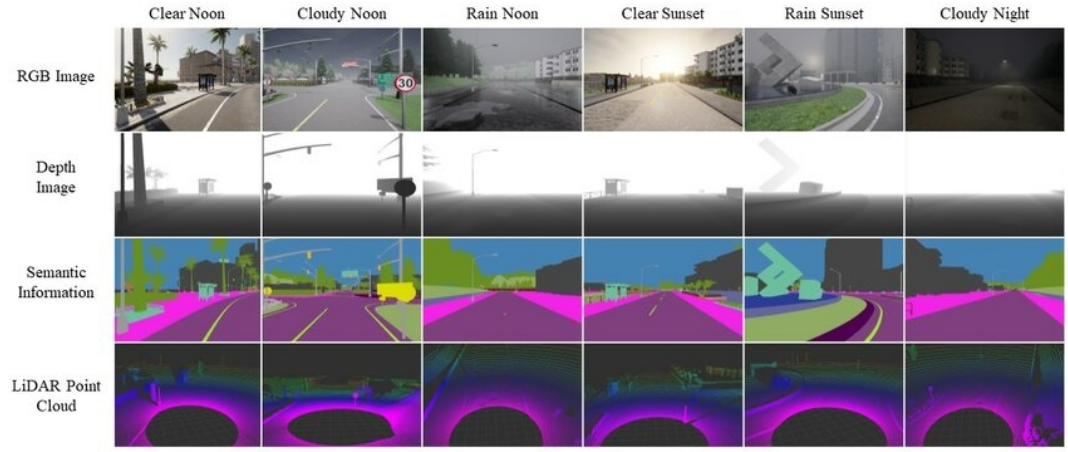
Bounding box – Ako YOLO uoči da u ćeliji postoji objekat, on predviđa koordinate pravougaonika (bounding box) koji okružuje objekat. [12]

Confidence score – za svaku ćeliju YOLO računa vrednost između 0 i 1 (confidence), koja označava sigurnost da se u toj ćeliji nalazi neki objekat. [12]

Class labels – YOLO takođe predviđa kojoj klasi objekat pripada (npr. car, person, traffic light). [12]

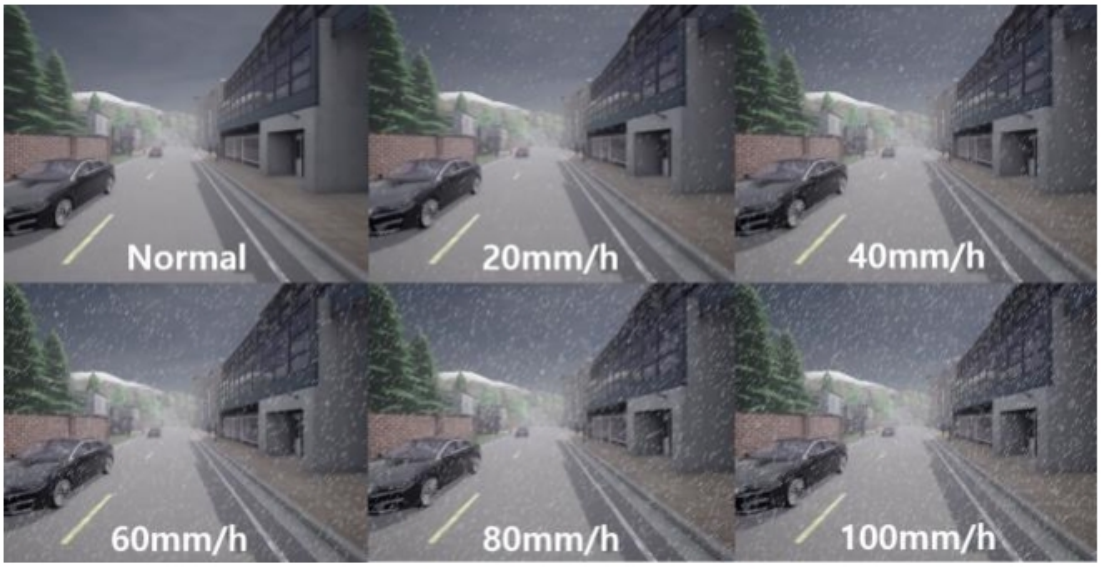


Slika 4. – Detekcija objekata u različitim vremenskim uslovima (sunčano, kišovito, noć), (slika preuzeta sa zvaničnog portfolija Deep Fusion, 2023)



Slika 5. – Primer iz CARLA simulatora (slika preuzeta sa ResearchGate: „Examples of our generated road data using the CARLA simulator“, 2023)

Na slici 5. se nalaze primeri scena kroz različite modalitete i vremenske uslove. Prvi red sadrži RGB Image, što predstavljaju obične kamere (slično kao što bismo videli ljudskim okom) koje prikazuju scenu u različitim vremenskim uslovima. Drugi red (Depth Image) prikazuje dubinske mape, gde svetlije nijanse označavaju bliže objekte, a tamnije udaljene. Treći red (Semantic Information) prikazuje svaku vrstu objekta kako je obeležena drugom bojom, što pomaže modelima da razlikuju šta je šta u sceni, a ne samo gde se nalazi. Četvrti red (LiDAR Point Cloud) prikazuje lasersko skeniranje koje daje 3D strukturu okoline, koja u kombinaciji sa kamerama omogućava precizno razumevanje okruženja i olakšava detekciju u lošim uslovima.



Slika 6. – Primer slika sa veštačkom kišom u različitim količinama padavina (slika preuzeta sa Kim et al., 2023)

4. Metodološki okvir istraživanja

4.1. Predmet istraživanja

Predmet istraživanja predstavlja prepoznavanje automobila na statičnim slikama snimljenim u kišnim uslovima. Poseban akcenat stavljen je na analizu uspešnosti detekcije u zavisnosti od intenziteta padavina (bez kiše, slaba kiša, jaka kiša) i boje automobila (posebno nijanse koje se približavaju boji kiše – sivkaste i svetlo plave nijanse).

4.2. Problem istraživanja

Iako su moderni algoritmi za detekciju objekata izuzetno efikasni u idealnim vizuelnim uslovima, njihova tačnost može biti značajno smanjena pri otežanim uslovima snimanja. Kiša utiče na kvalitet slike kroz smanjenje kontrasta, pojavu vizuelnog šuma (kapljice koje zasenčuju deo slike), difuzne refleksije i optičke izobličenja. Glavni problem ovog istraživanja jeste kvantifikacija pada performansi YOLO algoritma u zavisnosti od intenziteta kiše i boje vozila.

4.3. Cilj istraživanja

Cilj istraživanja jeste kvantitativno i kvalitativno utvrđivanje uspeha prepoznavanja automobila pomoću YOLO algoritma na slikama pogođenim različitim intenzitetom kiše, kao i utvrđivanje eventualnog uticaja boje automobila na tačnost detekcije.

4.4. Hipoteze

Glavna hipoteza: Moguće je prepoznavanje automobila pri kišnim uslovima korišćenjem YOLO algoritma.

Pothipoteza H1: Moguće je proceniti uspeh prepoznavanja automobila pri različitom intezitetu kiše.

Pothipoteza H2: Pri kišnim uslovima, boja automobila ima uticaj na uspešnost prepoznavanja.

4.5. Vrsta istraživanja

Istraživanje je eksperimentalnog tipa, sa kvantitativnom analizom rezultata dobijenih primenom YOLO algoritma na definisanim skupovima slika. Koristiće se postojeći javno dostupni datasetovi modifikovani dodatnim selekcijama i/ili augmentacijom kako bi se stvorile slike sa različitim intenzitetima kiše.

4.6. Način istraživanja

Testiraće se 4 grupe po otprilike 50 slika. Grupa A koja sadrži 50 slika bez kiše, grupa B koja sadrži 50 slika sa slabom kišom, grupa C koja sadrži 50 slika sa jakom kišom i grupa D koja sadrži automobile u kišnim uslovima sa bojom sličnoj kiši (sivkasto, svetlo plava ili slično).

Obrada testiranja će se vršiti unutar Google Colab okruženja.

5. Eksperimentalno istraživanje

5.1. Organizacija dataset-a u Google Drive

Za jednostavnu i ponovljivu reprodukciju eksperimenta koristiće se Google Drive kao skladište dataset-a. Struktura foldera u Google Drive će biti sledeća: MyDrive –> master_yolo –> dataset –> 4 različita foldera sa slikama. Svaka slika treba da ima jedinstveno ime (npr. A_001, B_048, itd.).

Prikupljanje slika je obavljano delom iz datasetova, delom ručno sa interneta, kao i delom sa pronalaženje primera sa google mapama.

5.2. Anotacija slika

Ako dataset nema anotacije, predlaže se korišćenje alata LabelImg (desktop) ili CVAT (web) za pravljenje bounding box anotacija u YOLO formatu. Anotacije treba da budu u formatu koji YOLOv8 očekuje (jedan .txt fajl po slici sa linijama: class x_center y_center width height u normalizovanim koordinatama).

U slučaju da se koriste gotove anotacije u COCO formatu, u Colab-u se mogu konvertovati u YOLO format koristeći skripte dostupne u mnogim repozitorijumima.

Za dataset koji je korišćen u istraživanju nisu rađene dodatne ručne anotacije, već su korišćene gotove oznake iz COCO formata koje su integrisane u YOLOv8 model. U Colab okruženju je sprovedeno filtriranje rezultata tako da se uzimaju u obzir samo anotacije klase car. Na taj način obezbeđeno je da algoritam vrši detekciju isključivo automobila, dok su ostale klase (poput truck, person i dr.) bile isključene iz analize.

5.3. Google Colab kod

Ovo je deo koda za instaliranje biblioteka – Ultralytics (za YOLOv8 model) [13] i Pandas, Seaborn i Matplotlib (za obradu podataka i vizualizacije).

```
!pip install ultralytics
!pip install pandas==2.2.2 seaborn matplotlib
```

Kod 1. – Instalacija biblioteka i priprema okruženja

Ovaj deo koda povezuje Colab sa Google Drive i definiše foldere "dataset" i "results".

```
from google.colab import drive
drive.mount('/content/drive', force_remount=True)

BASE_DIR = '/content/drive/MyDrive/master_yolo'
DATASET_DIR = BASE_DIR + '/dataset'
RESULTS_DIR = BASE_DIR + '/results'

import os
os.makedirs(RESULTS_DIR, exist_ok=True)
```

Kod 2. – Import Google Drive i kreiranje putanja

Ovaj deo koda učitava unapred istrenirani YOLOv8 model koji zna da detektuje objekte iz COCO dataseta.

```
from ultralytics import YOLO

# učitavanje YOLOv8 modela
model = YOLO('yolov8s.pt')
```

Kod 3. – Učitavanje YOLOv8 modela

Ovaj kod je funkcija koja prolazi kroz sve slike u folderu, detektuje samo automobile (klasa = 2), crta bounding box-ove oko automobila, rezultate čuva u JSON i CSV fajlovima, slike sa uokvirenim automobilima čuva u "predictions" folderu.

```
import json
import pandas as pd
import glob
import cv2

def detect_cars_only(model, folder, out_folder, conf=0.25, iou=0.45):
    os.makedirs(out_folder, exist_ok=True)
    pred_dir = os.path.join(out_folder, "predictions")
    os.makedirs(pred_dir, exist_ok=True)
```

```
    results = []
    rows = []

    for img_path in glob.glob(folder + '/*.jpg'):
        res = model.predict(source=img_path, conf=conf, iou=iou,
save=False, verbose=False)
        r = res[0]

        # učitavanje originalne slike
        img = cv2.imread(img_path)

        boxes = []
        for box in r.boxes:
            xyxy = [int(v) for v in box.xyxy.tolist()[0]]
            cls_id = int(box.cls.tolist()[0])
            conf_score = float(box.conf.tolist()[0])

            # filtriranje automobila (COCO: car = 2)
            if cls_id == 2:
                x1, y1, x2, y2 = xyxy
                cv2.rectangle(img, (x1, y1), (x2, y2), (255, 255,
255), 2)
                label = f"car {conf_score:.2f}"
                cv2.putText(img, label, (x1, y1-5),
cv2.FONT_HERSHEY_SIMPLEX, 0.6, (255,255,255), 2)

                boxes.append({'xyxy': xyxy, 'class': cls_id, 'conf':
conf_score})
                rows.append({'image': os.path.basename(img_path),
'x1': x1, 'y1': y1,
'x2': x2, 'y2': y2, 'class': cls_id,'conf': conf_score})

        # čuvanje slika sa automobilima
        out_img_path = os.path.join(pred_dir,
os.path.basename(img_path))
        cv2.imwrite(out_img_path, img)

        results.append({'image': os.path.basename(img_path),
'detections': boxes})

    # čuvanje u JSON
    with open(os.path.join(out_folder, 'raw_results.json'), 'w') as f:
        json.dump(results, f, indent=2)

    # čuvanje u CSV
    df = pd.DataFrame(rows)
    df.to_csv(os.path.join(out_folder, 'detections.csv'), index=False)

    return results
```

Kod 4. – Funkcija za detekciju automobila

Ovde se funkcija poziva za sve četiri grupe slika.

```
results_A = detect_cars_only(model, DATASET_DIR + '/A_no_rain',
RESULTS_DIR + '/A_no_rain')
results_B = detect_cars_only(model, DATASET_DIR + '/B_light_rain',
RESULTS_DIR + '/B_light_rain')
results_C = detect_cars_only(model, DATASET_DIR + '/C_heavy_rain',
RESULTS_DIR + '/C_heavy_rain')
results_D = detect_cars_only(model, DATASET_DIR + '/D_rain_color',
RESULTS_DIR + '/D_rain_color')
```

Kod 5. – Pokretanje detekcije za sve grupe slika

Ovde se učitavaju svi rezultati i spajaju u jednu tabelu df_all, što olakšava dalju analizu.

```
import seaborn as sns
import matplotlib.pyplot as plt

def load_csv(group):
    return pd.read_csv(os.path.join(RESULTS_DIR, group,
'detections.csv'))

df_A = load_csv('A_no_rain'); df_A['group'] = 'A_no_rain'
df_B = load_csv('B_light_rain'); df_B['group'] = 'B_light_rain'
df_C = load_csv('C_heavy_rain'); df_C['group'] = 'C_heavy_rain'
df_D = load_csv('D_rain_color'); df_D['group'] = 'D_rain_color'

df_all = pd.concat([df_A, df_B, df_C, df_D], ignore_index=True)
```

Kod 6. –Učitavanje rezultata i spajanje u jednu tabelu

U ovom delu koda se računa prosečna vrednost, standardna devijacija i broj detekcija za svaku grupu. Boxplot grafički prikazuje distribuciju confidence score-a po grupama.

```
summary =
df_all.groupby('group')['conf'].agg(['mean','std','count']).reset_inde
x()
print(summary)

plt.figure(figsize=(8,6))
sns.boxplot(data=df_all, x='group', y='conf')
plt.title('Distribucija confidence score-a po grupama')
plt.show()
```

Kod 7. – Statistika confidence score-a i boxplot

U ovom delu koda se čuvaju rezultati unutar CSV fajla i prikazuje se barplot prosečnog confidence score-a po grupama.

```
summary.to_csv(os.path.join(RESULTS_DIR, 'summary_metrics.csv'),
index=False)

summary = df_all.groupby('group')['conf'].mean().reset_index()

plt.figure(figsize=(8,6))
sns.barplot(data=summary, x='group', y='conf')
plt.title('Prosečan confidence po grupama')
plt.ylabel('Mean confidence')
plt.show()
```

Kod 8. – Prosečan confidence po grupama

Ovde se vrši analiza koliko je automobila detektovano po slici u svakoj grupi.

```
df_counts =
df_all.groupby(['group','image']).size().reset_index(name='car_count')

plt.figure(figsize=(8,6))
sns.boxplot(data=df_counts, x='group', y='car_count')
plt.title('Broj detekcija automobila po slici u različitim uslovima')
plt.show()
```

Kod 9. – Broj detekcija po slici

Ovaj deo koda prikazuje scatterplot gde je x-osa površina bounding box-a, a y-osa confidence score. Boje označavaju različite grupe uslova.

```
df_all['box_area'] = (df_all['x2'] - df_all['x1']) * (df_all['y2'] -
df_all['y1'])

plt.figure(figsize=(8,6))
sns.scatterplot(data=df_all, x='box_area', y='conf', hue='group')
plt.title('Confidence u zavisnosti od veličine bounding box-a')
plt.xlabel('Površina bounding box-a (px)')
plt.ylabel('Confidence')
plt.show()
```

Kod 10. – Odnos površine bounding box-a i confidence score-a

6. Pregled rezultata

Rezultati se mogu pratiti kroz strukturu generisanih fajlova i vizualne prikaze dobijenih detekcija u svakoj grupi slika, kao i prikaz različitih grafikona kreiranih u Google Colab kodu.

6.1. Razmatranje Google Drive foldera i rezultata različitih grupa slika

```
        # filtriranje automobila (COCO: car = 2)
        if cls_id == 2:
            x1, y1, x2, y2 = xyxy
            # uokvirenje samo automobila (izostavljanje ostalih vozila, objekata ili pešaka)
            cv2.rectangle(img, (x1, y1), (x2, y2), (255, 255, 255), 2)
            label = f"car {conf_score:.2f}"
            cv2.putText(img, label, (x1, y1-5), cv2.FONT_HERSHEY_SIMPLEX, 0.6, (255,255,255), 2)

            boxes.append({'xyxy': xyxy, 'class': cls_id, 'conf': conf_score})
            rows.append({'image': os.path.basename(img_path), 'x1': x1, 'y1': y1,
                         'x2': x2, 'y2': y2, 'class': cls_id, 'conf': conf_score})

    # čuvanje slika sa automobilima
    out_img_path = os.path.join(pred_dir, os.path.basename(img_path))
    cv2.imwrite(out_img_path, img)

    results.append({'image': os.path.basename(img_path), 'detections': boxes})

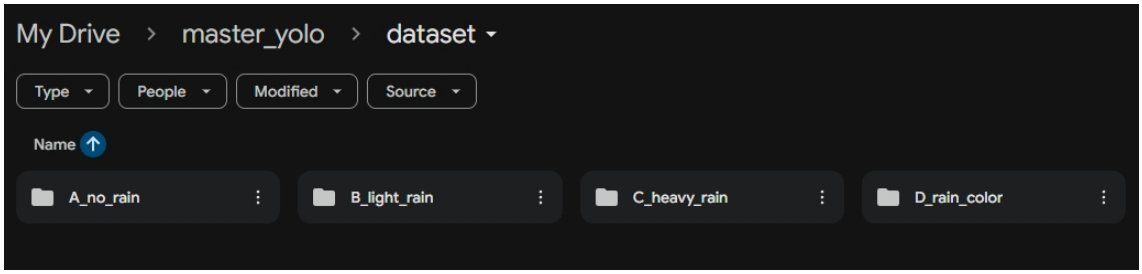
# čuvanje u JSON
with open(os.path.join(out_folder, 'raw_results.json'), 'w') as f:
    json.dump(results, f, indent=2)

# čuvanje u CSV
df = pd.DataFrame(rows)
df.to_csv(os.path.join(out_folder, 'detections.csv'), index=False)

return results
```

Slika 7. – Kod za filtriranje automobile

Na slici 2. se nalazi Colab kod koji je specifično namenjen da filtrira i detektuje samo automobile na svim slikama. Bez ovog koda, algoritam detektuje ostala vozila kao kamione, autobuse, objekte kao semafor, pešake itd. Takođe je specifirano da se uokvire samo automobili.



Slika 8. – Google Drive folder u kojem se nalaze kreirani rezultati nakon pokretanja koda

Na slici 3. se nalaze 4 različita foldera u kojima se nalaze različite grupe slika za testiranje. Folder grupe A sadrži slike automobila bez kiše, folder grupe B sadrži slike automobila sa slabijom kišom, folder C sadrži slike automobila sa jačom kišom i folder grupe D sadrži slike automobila sličnih boja kiši.

Kada se pokrene kod u Google Colab, on pravi dodatan folder koji se naziva "results" i on sadrži sva 4 foldera različitih grupa slika u kojima se nalaze **detections.csv**, **raw_results.json** i **predictions**.

detections.csv — Open with

	A	B	C	D	E	F	G
1	image	x1	y1	x2	y2	class	conf
2	A_023.jpg	139	161	375	265	2	0.9380921125
3	A_022.jpg	260	65	751	291	2	0.9333204627
4	A_017.jpg	43	215	1140	746	2	0.8018024564
5	A_024.jpg	408	325	3092	1806	2	0.9459710121
6	A_025.jpg	420	194	1146	585	2	0.9001925588
7	A_026.jpg	158	313	1286	832	2	0.9075750113
8	A_027.jpg	20	64	238	170	2	0.8984335065
9	A_027.jpg	0	89	25	109	2	0.8342779279
10	A_018.jpg	66	117	1116	586	2	0.9152940512
11	A_020.jpg	130	197	1841	1087	2	0.9446877241
12	A_019.jpg	88	149	681	444	2	0.9412224293
13	A_019.jpg	597	124	748	259	2	0.9220038056
14	A_021.jpg	86	154	694	472	2	0.8895708919
15	A_007.jpg	75	0	83	20	2	0.6226502657
16	A_007.jpg	69	0	77	16	2	0.3380638957
17	A_008.jpg	15	18	76	56	2	0.4489414692
18	A_008.jpg	44	19	47	21	2	0.3036366403
19	A_008.jpg	46	18	49	20	2	0.2822842896
20	A_009.jpg	14	6	115	102	2	0.7304417491
21	A_012.jpg	51	0	81	8	2	0.612197578
22	A_028.jpg	399	173	511	264	2	0.8766974807
23	A_028.jpg	162	198	216	230	2	0.8375785351
24	A_028.jpg	500	194	541	249	2	0.8110518456
25	A_028.jpg	530	193	593	239	2	0.7189236283
26	A_028.jpg	328	202	365	226	2	0.6129117012
27	A_028.jpg	374	195	405	230	2	0.5823718309
28	A_029.jpg	0	203	213	388	2	0.9046630859
29	A_029.jpg	263	204	378	284	2	0.8994450569
30	A_029.jpg	505	202	562	251	2	0.8188273907
31	A_029.jpg	485	201	514	235	2	0.5596550703

Slika 9. – Google Drive detections.csv fajl

Na slici 4. se nalazi fajl detections.csv koji prikazuje više kolona:

- image – ime slike iz te grupe slika
- x1, y1, x2, y2 – coordinate bounding box-a (pravougaonik oko automobila)
- class – oznaka klase objekta (u COCO dataset-u class=2 znači automobil)
- conf – confidence score (0-1), sigurnost YOLO algoritma da je to što je zabeležio zaista automobile

```
[
  {
    "image": "A_023.jpg",
    "detections": [
      {
        "xyxy": [
          139,
          161,
          375,
          265
        ],
        "class": 2,
        "conf": 0.9380921125411987
      }
    ]
  },
  {
    "image": "A_022.jpg",
    "detections": [
      {
        "xyxy": [
          260,
          65,
          751,
          291
        ],
        "class": 2,
        "conf": 0.9333204627037048
      }
    ]
  },
  {
    "image": "A_017.jpg",
    "detections": [
      {
        "xyxy": [
          43,
          215,
          1140,
          746
        ],
        "class": 2,
        "conf": 0.8018024563789368
      }
    ]
  },
```


Slika 10. – Google Drive raw_results.json fajl

Na slici 5. se vidi raw_results.json fajl koji sadrži sirove rezultate YOLO algoritma u JSON format. Za svaku sliku je napisano ime slike, lista svih detektovanih automobile, njihove coordinate i nivo sigurnosti detekcije. Ovaj fajl omogućava detaljnu analizu i čuvanje rezultata, dok se CSV fajl koristi za tabelarne prikaze i statističku obradu.

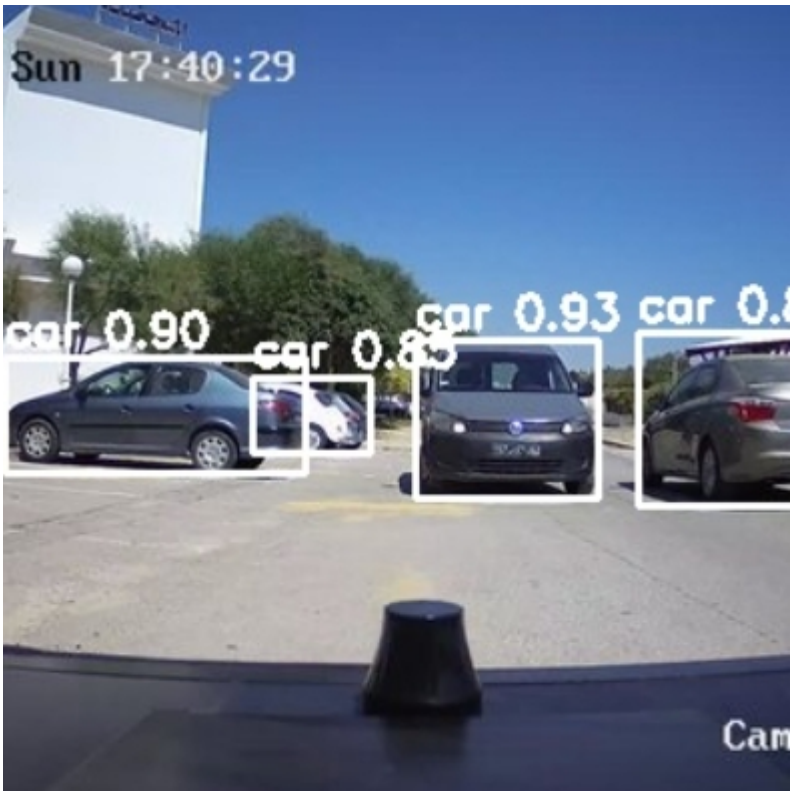
Sledeći i poslednji folder koji se kreira unutar Google Drive je "predictions" folder u kojem se nalaze sve slike koje su postavljene za testiranje, ali su u ovom folderu vraćene sa rezultatima označenih automobila.

6.2. Rezultati slika grupe A

Sledeći rezultati koji se prikazuju su slike automobila bez kiše (grupa A).



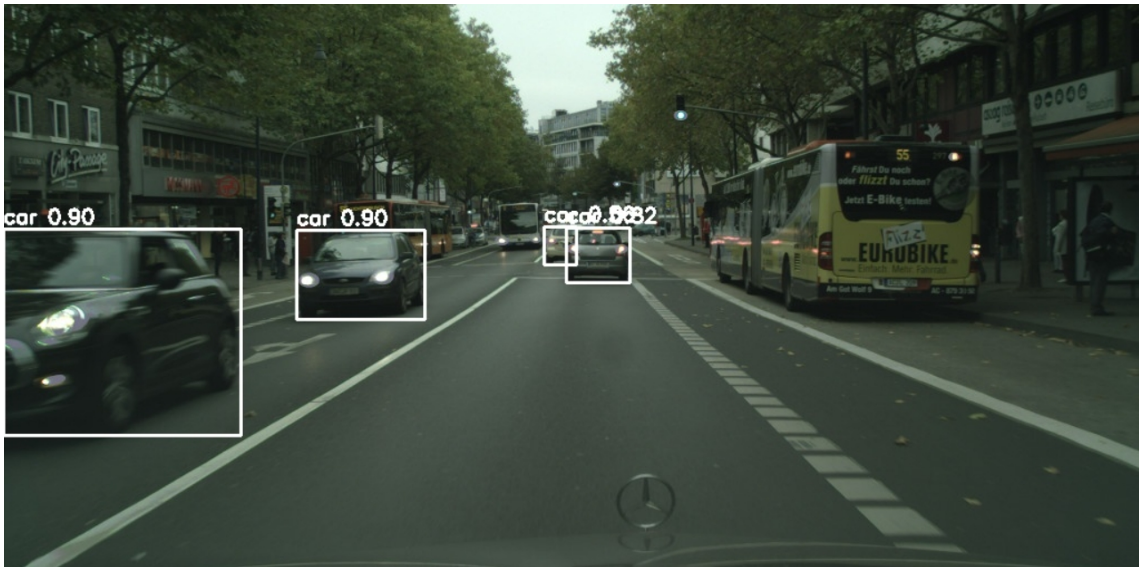
Slika 11. – Primer rezultata grupe_A, automobila bez kiše (A_026)



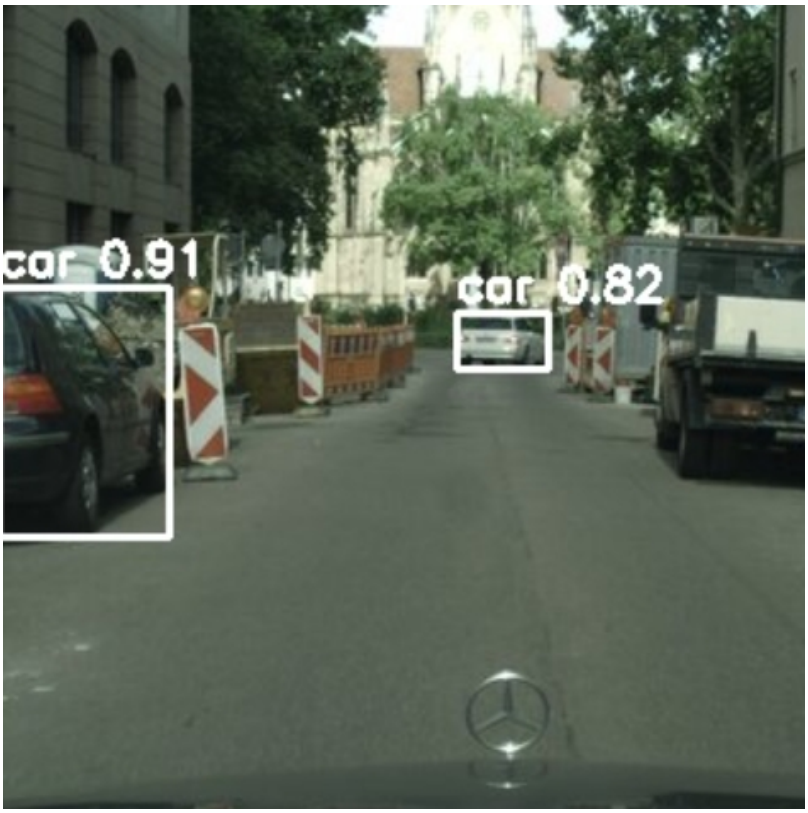
Slika 12. – Primer rezultata grupe_A, automobila bez kiše (A_035)



Slika 13. – Primer rezultata grupe_A, automobila bez kiše (A_034)



Slika 14. – Primer rezultata grupe_A, automobila bez kiše (A_029)



Slika 15. – Primer rezultata grupe_A, automobila bez kiše (A_042)



Slika 16. – Primer rezultata grupe_A, automobila bez kiše (A_033)

Na slikama sa primerima rezultata od slike 11. do slike 16. (za grupu A, automobili bez prisustva kiše) se može videti kako YOLO bez problema pronalazi sve vidljive automobile na slici i uokviruje ih sa confidence nivo-om koji pokazuje koliko je YOLO siguran da je to zaista automobile što je uokvirio.

6.3. Rezultati slika grupe B

Sledeći rezultati koji se prikazuju su slike automobila sa prisustvom slabije kiše (grupa B).



Slika 17. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_003)



Slika 18. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_010)



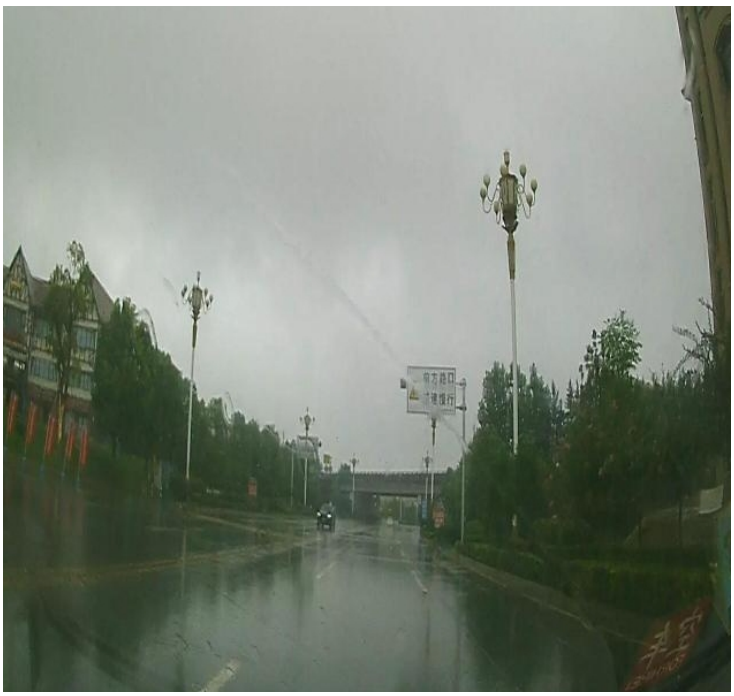
Slika 19. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_016)

Na slici 19. može da se uoči da YOLO pogrešno tumači sliku i prepoznaje crtež na zidu kao da je automobil.



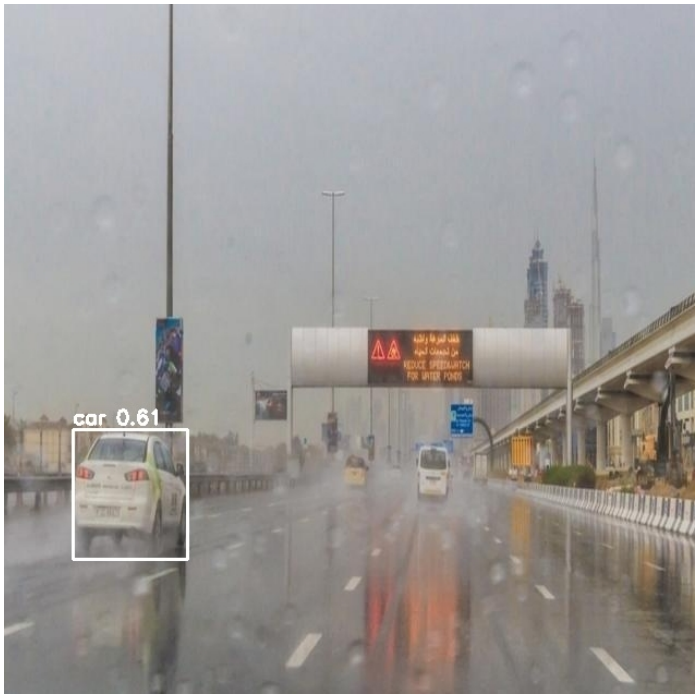
Slika 20. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_025)

Na slici 20. se može uočiti da YOLO algoritam prepoznaje beli automobil, ali crni džip pored njega ne obeležava jer ima posebnu vrstu oznake za taj tip vozila kome inače daje naziv "truck". Takođe ne uočava automobil koji je na velikoj daljini na slici.



Slika 21. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_037)

Na slici 21. se može uočiti da YOLO uopšte ne prepoznaje da se na slici nalazi automobil koji se približava na levoj traci.

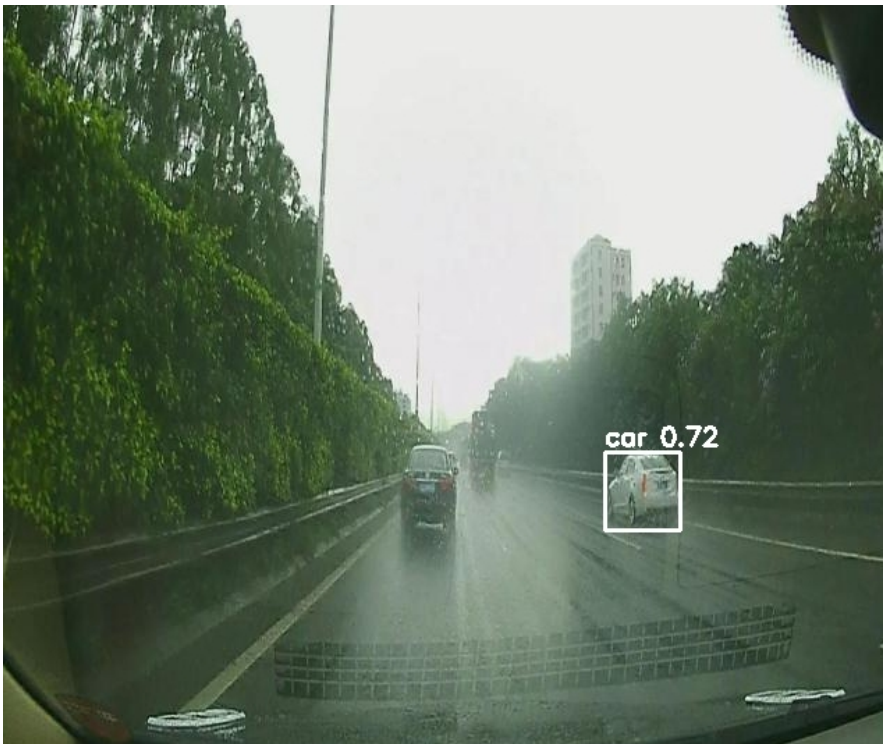


Slika 22. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_047)

Na slici 22. YOLO beleži samo levi najbliži automobil, dok žuti automobil u daljini ne prepoznaje od količine kiše na putu.



Slika 23. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_036)



Slika 24. – Primer rezultata grupe_B, automobila sa slabijom kišom (B_039)

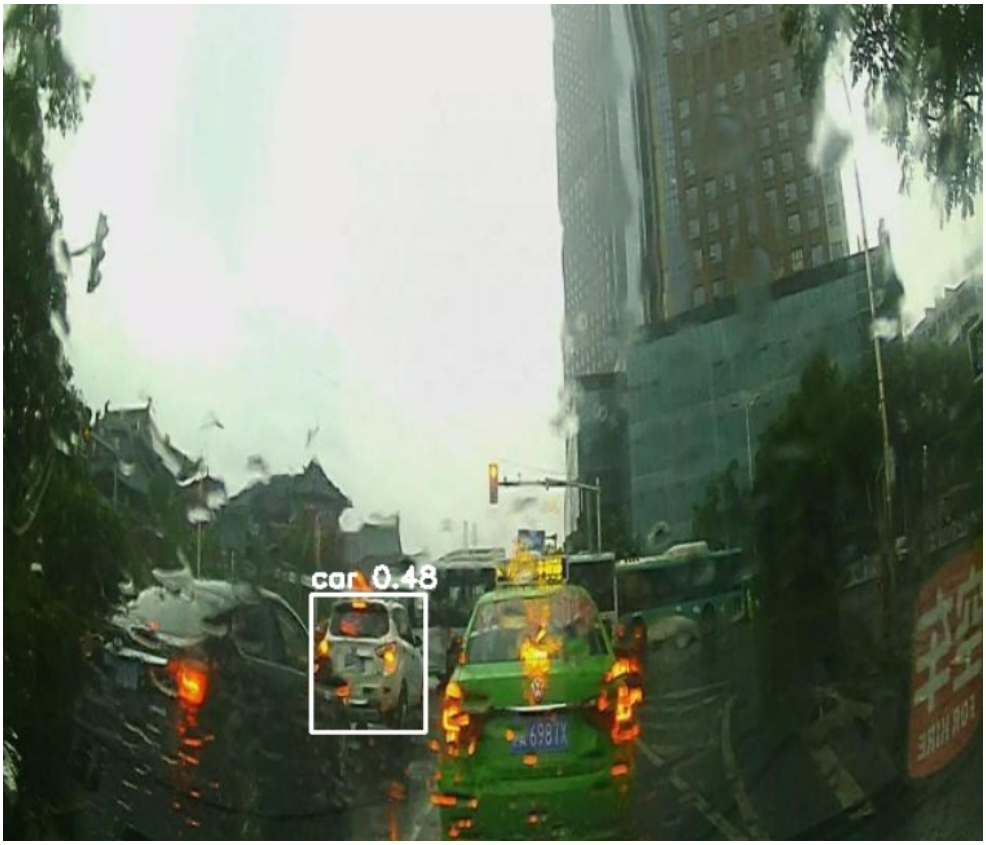
6.4. Rezultati slika grupe C

Sledeći rezultati koji se prikazuju su slike automobila sa prisustvom jake kiše (grupa C).



Slika 25. – Primer rezultata grupe_C, automobila sa jakom kišom (C_001)

Na slici 25. algoritam ne može da prepozna neke automobile zbog prevelikih distorcija od kiše na staklu i jačine osvetljenja farova i zadnjih svetala.



Slika 26. – Primer rezultata grupe_C, automobila sa jakom kišom (C_002)



Slika 27. – Primer rezultata grupe_C, automobila sa jakom kišom (C_003)



Slika 28. – Primer rezultata grupe_C, automobila sa jakom kišom (C_011)



Slika 29. – Primer rezultata grupe_C, automobila sa jakom kišom (C_012)



Slika 30. – Primer rezultata grupe_C, automobila sa jakom kišom (C_033)



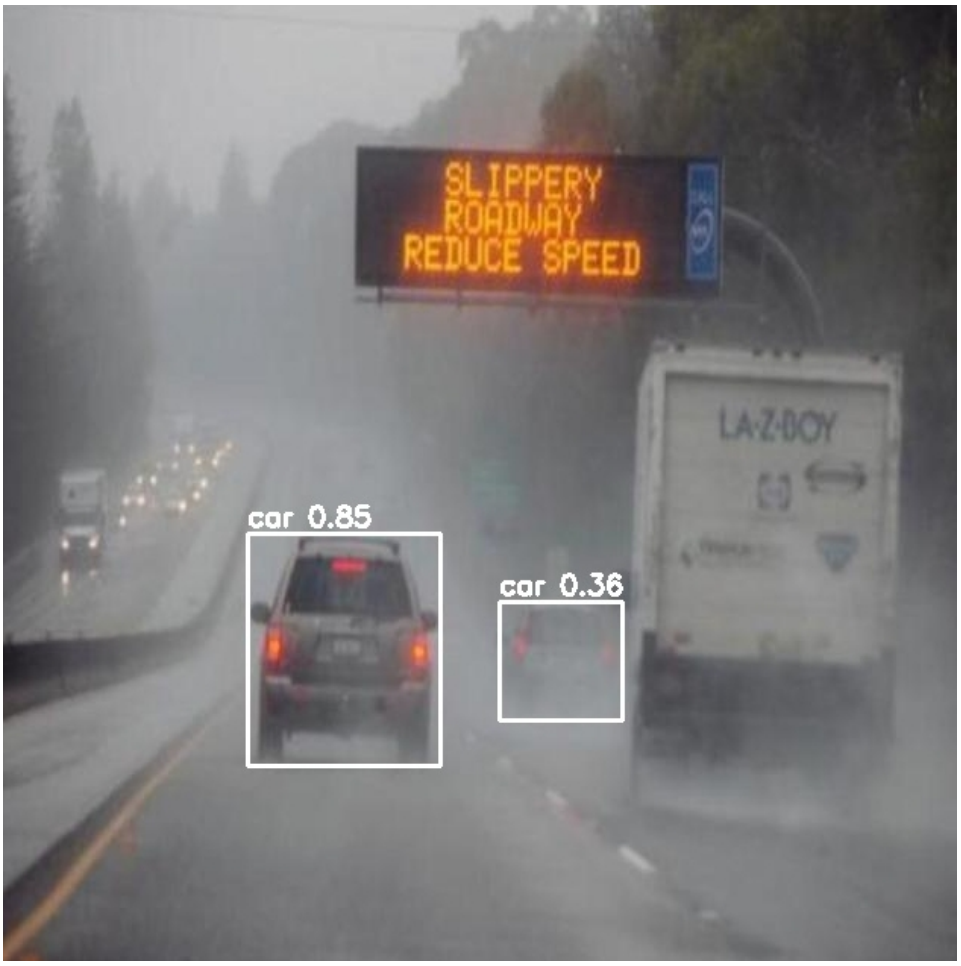
Slika 31. – Primer rezultata grupe_C, automobila sa jakom kišom (C_035)



Slika 32. – Primer rezultata grupe_C, automobila sa jakom kišom (C_034)



Slika 33. – Primer rezultata grupe_C, automobila sa jakom kišom (C_013)



Slika 34. – Primer rezultata grupe_C, automobila sa jakom kišom (C_017)



Slika 35. – Primer rezultata grupe_C, automobila sa jakom kišom (C_030)



Slika 36. – Primer rezultata grupe_C, automobila sa jakom kišom (C_031)

6.5. Rezultati slika grupe D

Sledeći rezultati koji se prikazuju su slike automobila sa bojom sličnoj kiši (grupa D), odnosno automobili koji su bele, sivkaste, svetlo plave boje ili slično.



Slika 37. – Primer rezultata grupe_D, automobila sa sličnom bojom kao kiša (D_002)



Slika 38. – Primer rezultata grupe_D, automobila sa sličnom bojom kao kiša (D_007)



Slika 39. – Primer rezultata grupe_D, automobila sa sličnom bojom kao kiša (D_011)

Na slici 39. se nalaze automobili tri različite boje, ali YOLO i dalje uspeva da obeleži i detektuje sva tri automobila.

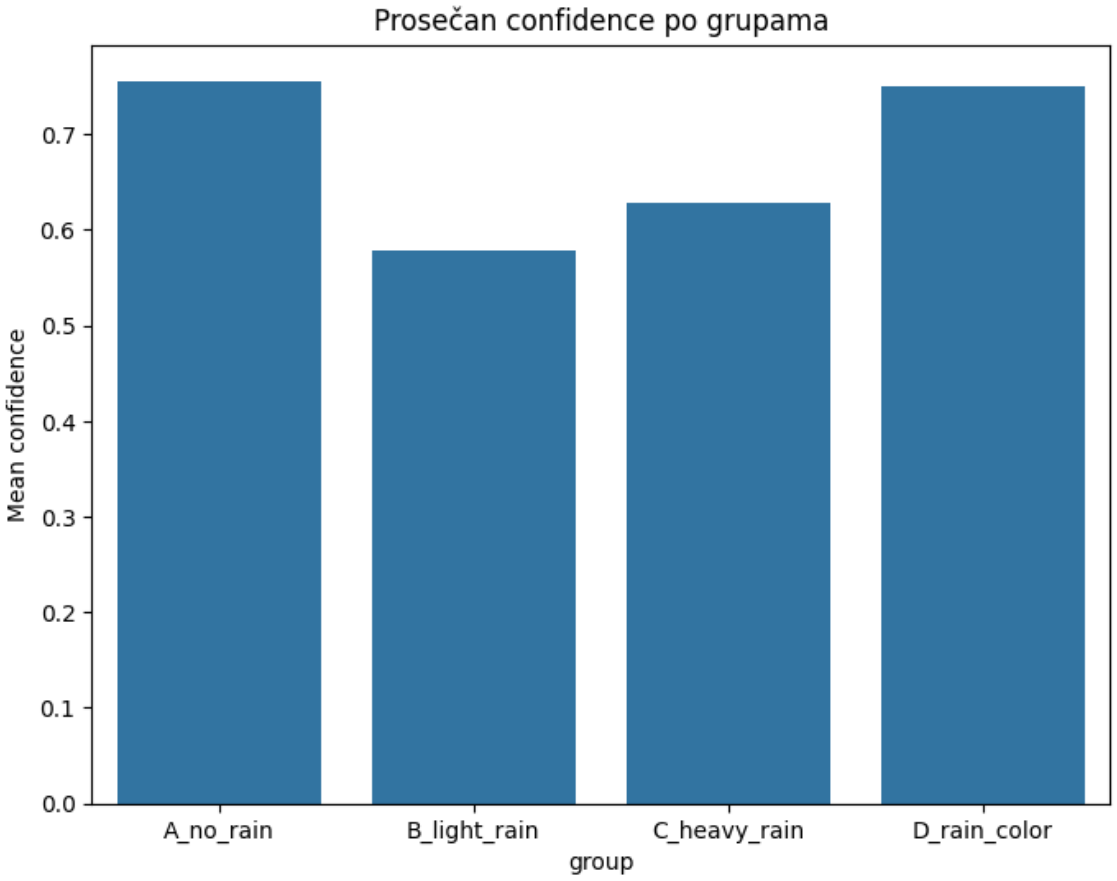


Slika 40. – Primer rezultata grupe_D, automobila sa sličnom bojom kao kiša (D_012)

Na slici 40. YOLO uspeva da detektuje automobil, nasuprot tome što je u sivkastoj boji i što prska mnogo vode oko automobila.

6.6. Prikaz rezultata na grafikonima

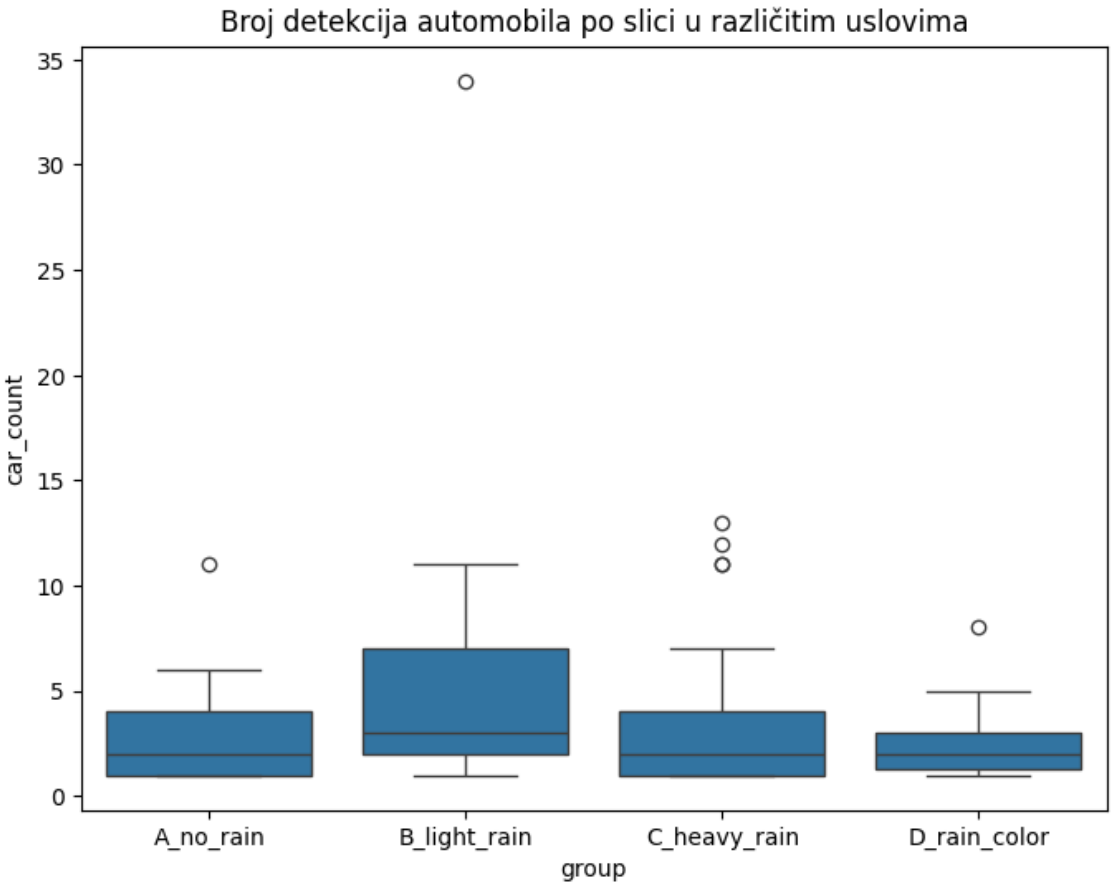
U ovom poglavlju rezultati detekcije su prikazani u obliku grafičkih dijagrama. Grafikoni omogućavaju da se na pregledan način sagleda razlika u performansama algoritma YOLOv8 pri detekciji automobila u zavisnosti od vremenskih uslova. Na grafikonima se mogu uočiti razlike između četiri grupe slika (bez kiše, slaba kiša, jaka kiša i automobili u boji kiše) u pogledu prosečnog confidence score-a (sigurnost YOLO algoritma da je zaista obeležio automobil), broja detekcija po slici i zavisnosti pouzdanosti od veličine bounding box-a (pravougaonik oko automobila).



Slika 41. – Prikaz Bar Chart dijagrama

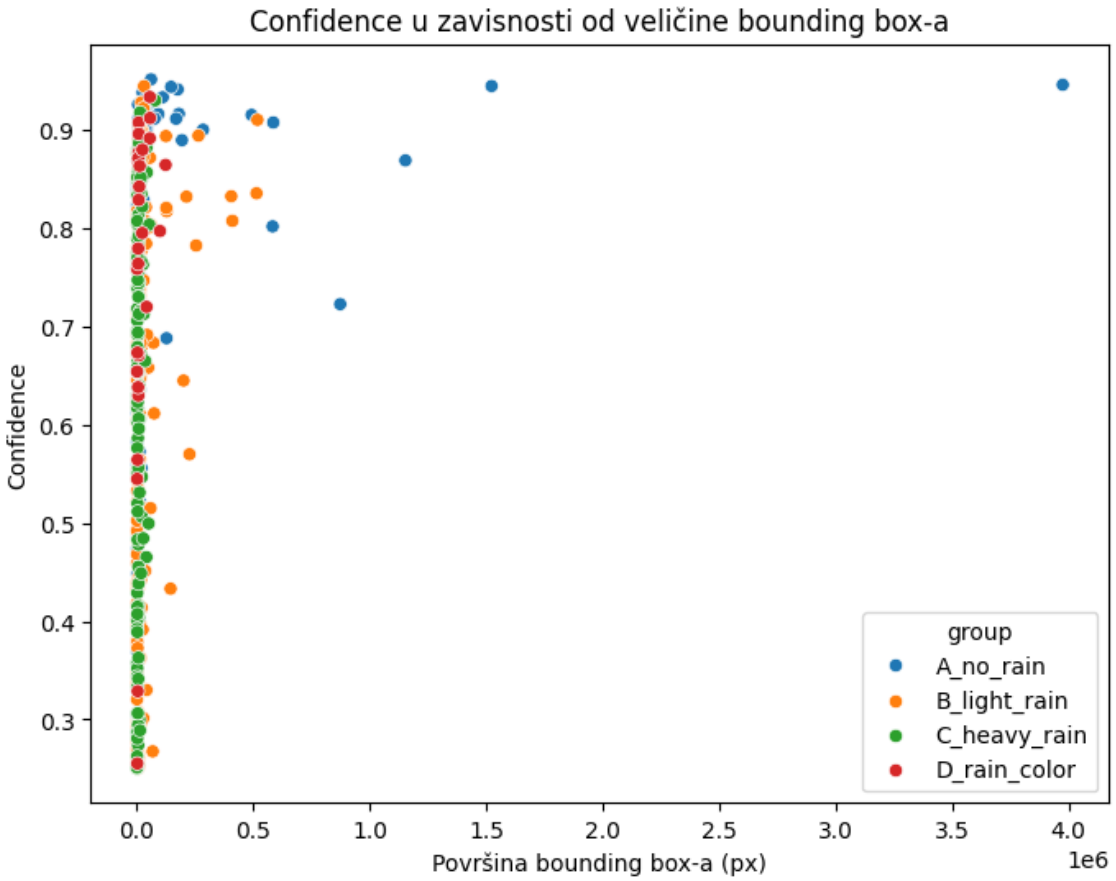
Na slici 41. se nalazi Bar Chart dijagram koji prikazuje prosečan confidence score po grupama slika. Svaki stub predstavlja prosečnu sigurnost YOLO algoritma da je ispravno prepoznao i označio automobil u toj grupi slika.

Vidi se da se na grupi A (slike automobila bez kiše) algoritam oseća najsigurnije da je označio automobile, dok se kod grupe B i C (slabija i jaka kiša) znatno smanjuje njegova sigurnost, a kod grupe D (automobili sa bojom sličnoj kiši) nešto manja sigurnost od grupe A.



Slika 42. – Prikaz boxplot grafikona

Na slici 42. se nalazi boxplot grafikon koji pokazuje koliko je automobila YOLO uspeo da detektuje po slici za svaku grupu. Tačkice predstavljaju najveću vrednost, dok su plavi grafikoni srednje vrednosti po slici.



Slika 43. – Prikaz Scatter plot grafikona

Na slici 43. se prikazuje sigurnost YOLO algoritma u zavisnosti od veličine automobila na slici. X osa je veličina okvira koji YOLO povuče oko automobila, u pikselima, što je u stvari detektovana veličina samog vozila na slici. Y osa predstavlja koliko je YOLO siguran da je to stvarno automobil. Tačkice različitih boja predstavljaju različite grupe slike, kao što je prikazano dole desno na legendi. Svaka tačkica predstavlja jedan automobil sa informacijom koliko je velik na slici i kolika je sigurnost.

6.7. Zaključak rezultata

Na osnovu grafikona i rezultata može se zaključiti da YOLO algoritam pouzdano detektuje automobile u suvim uslovima, dok u prisustvu kiše značajno smanjuje sigurnost i preciznost detekcije. Pojava lažno pozitivnih detekcija ukazuje na potrebu dodatnog treniranja ili prilagođavanja algoritma za rad u realnim meteorološkim situacijama.

7. Zaključak

Rezultati su pokazali da atmosferski uslovi značajno utiču na performanse algoritma, pri čemu dolazi do smanjenja prosečne pouzdanosti detekcije i povećanja broja lažno pozitivnih detekcija.

Analiza četiri eksperimentalne grupe (bez kiše, slaba kiša, jaka kiša, automobili boje slične kiši) pokazala je sledeće:

- Najviša prosečna vrednost confidence score-a (~0.75) postignuta je u uslovima bez padavina i kod automobila sa bojom sličnom boji kiše
- Najlošiji rezultati zabeleženi su kod slabe kiše (~0.58), gde kapljice i odsjaji stvaraju dodatni vizuelni šum koji zbunjuje algoritam
- Jaka kiša dovela je do smanjenja pouzdanosti, ali nešto boljih rezultata nego pri slaboj kiši (~0.62)
- Pored smanjenja prosečnog confidence score-a, primećene su i značajne varijacije u broju detektovanih automobila po slici, sa ekstremnim outlier vrednostima u kišnim uslovima, što ukazuje na lažno pozitivne detekcije

Dodatnom analizom kroz grafikone i tabele uočeno je da veličina automobila na slici ima ključnu ulogu — što je automobil veći i bliži, YOLO ga pouzdanije prepoznaje. Kod manjih i udaljenih automobila confidence vrednosti značajno opadaju, naročito pri kišnim uslovima. Ovo ukazuje na ograničenja u realnim scenarijima, gde vidljivost i vremenski faktori igraju veliku ulogu.

Hipoteze definisane na početku istraživanja su potvrđene:

- Potvrđeno je da je moguće prepoznavanje automobila pri kišnim uslovima, iako sa smanjenom tačnošću
- Potvrđeno je da intenzitet kiše utiče na uspeh prepoznavanja, pri čemu slabija kiša paradoksalno pravi više problema zbog odsjaja i kapljica nego jaka kiša
- Potvrđeno je da boja automobila u određenim slučajevima utiče na detekciju, ali rezultati ukazuju da efekat nije presudan i da su potrebni veći dataset-ovi da bi se ovo detaljnije proverilo

Na osnovu dobijenih rezultata može se zaključiti da je YOLOv8 algoritam pouzdan u standardnim uslovima, ali ima ograničenja u složenim meteorološkim okolnostima. Buduća istraživanja mogla bi uključiti:

- korišćenje dodatnih dataset-ova sa realnim snimcima u saobraćaju
- kombinovanje YOLO algoritma sa tehnikama za poboljšanje kvaliteta slike (npr. uklanjanje šuma ili „image enhancement“ pri kiši)
- i evaluaciju performansi drugih verzija YOLO modela (npr. YOLOv5, YOLOv7) radi uporedne analize

8. Literatura

1. Jocher, G., Chaurasia, A., Stoken, A., Borovec, J., et al. (2023). Ultralytics YOLOv8. https://github.com/ultralytics/ultralytics
2. Google Colab Documentation. https://colab.research.google.com/
3. McKinney, W. (2017). Python for Data Analysis. O'Reilly Media.
4. Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2020). YOLOv4: Optimal Speed and Accuracy of Object Detection. arXiv:2004.10934.
5. Deep Fusion. (2023). Portfolio – Computer Vision Projects.
6. VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly Media.
7. Seaborn Documentation. Statistical Data Visualization. https://seaborn.pydata.org/
8. OpenCV Documentation. Open Source Computer Vision Library. https://docs.opencv.org/
9. Redmon, J., & Farhadi, A. (2018). YOLOv3: An Incremental Improvement. arXiv:1804.02767.
10. Kim, T., Jeon, H., & Lim, Y. (2023). Challenges of YOLO Series for Object Detection in Extremely Heavy Rain: CARLA Simulator based Synthetic Evaluation Dataset. arXiv:2312.07976.
11. Dosovitskiy, A., Ros, G., Codevilla, F., Lopez, A., & Koltun, V. (2017). CARLA: An Open Urban Driving Simulator. Proceedings of the 1st Annual Conference on Robot Learning (CoRL).
12. Sharma, S., & Sharma, P. Classification and Counting of Vehicle using Image Processing Techniques.
13. Ultralytics Blog. Train YOLOv8 on Custom Data. https://docs.ultralytics.com/
14. Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.